

การจัดอันดับบทความวิจัยสำหรับการค้นหาภาพทั่วไปในคลังเอกสาร

Literature Recommendation for Multimodal Search in Document Repositories

บทนำและความต้องการทางวิจัย

เมื่อเป้าหมายของระบบคือการพัฒนา **คลังเอกสารวิชาการ (Paper Repository)** ที่สามารถค้นหาข้อมูลเชิงข้อความและภาพประกอบได้ โดยที่รูปภาพภายในเอกสารไม่ได้จำกัดเฉพาะกราฟิกเชิงข้อมูล (Charts/Graphs) แต่ครอบคลุมถึง **ภาพทั่วไป (Natural/Generic Images)** เช่น ภาพถ่ายสัตว์ (สุนัข, แมว) พืชพรรณ หรือป่าไม้ โครงสร้างสถาปัตยกรรมของโมเดลสำหรับการประมวลผลจึงต้องมีความสามารถในการผสานข้อมูลข้ามโมดาลิตี้ (Multimodal Fusion) และสืบค้นเชิงบริบท (Context-Aware Retrieval) ที่ยืดหยุ่นกว่าเดิม

บทความวิจัยต่าง ๆ ในคลังจึงถูกจัดลำดับความสำคัญตามความสอดคล้องกับโจทย์นี้ เพื่ออำนวยความสะดวกในการศึกษาและออกแบบระบบ

ลำดับการอ่านเปเปอร์ที่แนะนำ (Paper Reading Ranking)

อันดับ	ชื่อบทความวิจัย	จุดโฟกัสหลัก	ความเชื่อมโยงกับระบบสืบค้นภาพทั่วไป
1	MIND-RAG (2025)	Multimodal RAG	แปลงภาพทั่วไปเป็นข้อความเชิงบริบทเพื่อเสิร์ช
2	LaMPCap (2025)	Diverse Figures	ชุดข้อมูลภาพหลากหลายประเภทพร้อมโปรไฟล์
3	AuthorContextSciCap (2025)	Multi-stage Pipeline	การกรองบริบทและการอัปเดตโมเดลตามประเภทภาพ
4	FigCaps-HF (2023)	Descriptive Captions	การเขียนคำอธิบายภาพระดับคุณภาพเพื่อเสิร์ช
5	SciCap+ (2023)	Context Importance	การใช้ย่อน้ำที่อ้างอิงรูปภาพแทนพิกเซลดิบ
6	RAG Survey (2024)	System Architecture	โครงสร้างระบบฐานข้อมูลและการค้นคืนข้อมูลทั่วไป

การวิเคราะห์เปเปอร์เชิงลึก (Detailed Analysis)

อันดับที่ 1: MIND-RAG (2025)

MIND-RAG: Multimodal Context-Aware and Intent-Aware Retrieval-Augmented Generation for Educational Publications

* **ทำไมต้องอ่านอันดับแรก:** เป็นงานวิจัยชิ้นที่ใกล้เคียงกับแนวคิดคลังเอกสารสืบค้นรูปภาพมากที่สุด โดยพัฒนาขึ้นเพื่อแก้ปัญหาความซับซ้อนของรูปภาพวิชาการที่ระบบ RAG ทั่วไปสืบค้นไม่ได้ผล * **เทคโนโลยีที่ตอบโจทย์:** นำเสนอแนวคิด **Context-Aware Image Summarization** โดยนำรูปภาพทั่วไปไปผสานเข้ากับย่อหน้าข้างเคียงหรือคำอธิบายภาพ เพื่อป้อนให้โมเดลประมวลผลภาพรวมภาพ (MLLM) สร้างเป็นข้อความสรุปความหมายความหนาแน่นสูง (Semantic Summary) จากนั้นจึงทำการฝังเวกเตอร์ (Embedding) ทำให้เราสามารถค้นหารูปภาพทั่วไป (เช่น ภาพหมา แมว หรือป่าไม้) ผ่านคีย์เวิร์ดที่เป็นข้อความธรรมดาได้อย่างแม่นยำ

อันดับที่ 2: LaMPCap (2025)

LaMPCap: Personalized Figure Caption Generation With Multimodal Figure Profiles

* **ทำไมต้องอ่านอันดับสอง:** เปเปอร์นี้ขยายขอบเขตของการประมวลผลรูปภาพประกอบในเปเปอร์วิชาการจากการเน้นเฉพาะกราฟฟิกส์ (Graph Plots) ไปสู่ภาพประเภทอื่น ๆ ที่มีความหลากหลายในเอกสาร (เช่น ภาพถ่ายสัตว์ แผนผัง ไดอะแกรม หรือสมการ) * **เทคโนโลยีที่ตอบโจทย์:** โครงสร้างของข้อมูลมีระบบประวัติภาพประกอบ (Figure Profiles) ในเปเปอร์เดียวกัน ซึ่งช่วยสร้างคุณลักษณะเชิงบริบทหลายมิติที่เป็นประโยชน์ต่อการสร้างดัชนีภาพประกอบที่มีความหลากหลายในเล่มวิชาการ

อันดับที่ 3: AuthorContextSciCap (2025)

Leveraging Author-Specific Context for Scientific Figure Caption Generation: 3rd SciCap Challenge

* **ทำไมต้องอ่านอันดับสาม:** เป็นการพัฒนาต่อยอดบนฐานชุดข้อมูลของ LaMPCap โดยมุ่งเน้นไปที่ท่อนส่งข้อมูลการประมวลผลรูปภาพแบบสองขั้นตอน (Two-stage Pipeline) * **เทคโนโลยีที่ตอบโจทย์:** การใช้กระบวนการ ****Category-Specific Prompt Optimization**** เพื่อกรองบริบทและแยกจัดการรูปภาพตามประเภทของภาพอย่างเป็นสัดส่วน ช่วยลดข้อจำกัดเมื่อระบบต้องรองรับภาพทั่วไปที่มีความหมายแตกต่างกันอย่างสิ้นเชิง

อันดับที่ 4: FigCaps-HF (2023)

FigCaps-HF: A Figure-to-Caption Generative Framework and Benchmark with Human Feedback

* **ทำไมต้องอ่านอันดับสี่:** การที่ระบบจะสืบค้นภาพถ่ายธรรมชาติทั่วไปได้ดี ข้อความบรรยายประกอบ (Caption) ต้องมีประสิทธิภาพในการบ่งบอกลักษณะเด่นของรูปภาพได้สอดคล้องกับพฤติกรรมมนุษย์ * **เทคโนโลยีที่ตอบโจทย์:** วิธีการปรับจูนน้ำหนักโมเดลด้วยคำวิจารณ์ของมนุษย์ (RLHF) เพื่อลดความคลุมเครือของคำบรรยาย และกระตุ้นให้เกิดการดึงข้อมูลเชิงทัศนศิลป์ (Visual aspects) และข้อความอักษรบนภาพออกมาช่วยในการทำดัชนีสืบค้น

อันดับที่ 5: SciCap+ (2023)

SciCap+: A Knowledge-Augmented Dataset for Scientific Figure Captioning

* **ทำไมต้องอ่านอันดับห้า:** เปเปอร์นี้นำเสนอข้อมูลการทดลองสำคัญที่ว่า ย่อหน้าที่อ้างอิงรูปภาพ (Figure-mentioning paragraphs) ส่งผลต่อประสิทธิภาพในการเข้าใจและอธิบายความหมายรูปภาพมากกว่าข้อมูลเชิงพิกเซลของภาพ (Visual features) จากโมเดลแบบ ResNet * **เทคโนโลยีที่ตอบโจทย์:** ยืนยันแนวทางการสร้างคลังข้อมูลที่เป็นต้องผูก รูปภาพเข้ากับข้อความอ้างอิงในเอกสารต้นฉบับ เพื่อใช้เป็นฐานการค้นคืนที่มีความสัมพันธ์เชิงความหมาย (Semantic relation)

อันดับที่ 6: RAG Survey (2024)

Retrieval Augmented Generation (RAG) and Beyond: A Comprehensive Survey...

* **ทำไมต้องอ่านอันดับหก:** เหมาะสำหรับการทำความเข้าใจโครงสร้างเชิงระบบของการจัดเก็บข้อมูล การแบ่งส่วน (Chunking) และการจัดทำดัชนีระบบสืบค้น RAG ในภาพรวม

กลุ่มบทความที่ไม่ตรงกับความต้องการในโจทย์นี้

มีบทความบางส่วนที่เน้นไปที่ทักษะเฉพาะเจาะจงทางสถิติและคณิตศาสตร์ ซึ่งไม่ควรนำมาใช้เป็นฐานสำหรับโจทย์ภาพทั่วไป (เช่น ภาพหมา แมว หรือสิ่งแวดล้อม):

- **DePlot (2023) / MatCha (2022) / UniChart (2023):** มุ่งเน้นการแก้ปัญหาประเภท Plot-to-Table หรือการแปลงภาพแผนภูมิแท่ง/แผนภูมิเส้นให้กลับไปเป็นตารางข้อมูลเพื่อทำความเข้าใจเชิงตัวเลข (Numerical Reasoning) โมเดลประเภทนี้จะล้มเหลวทันทีเมื่อประมวลผลภาพทั่วไป
- **SciCap (2021) [Original]:** ทำการคัดกรองรูปภาพประเภทอื่น ๆ ออกจากชุดข้อมูลทั้งหมด คงเหลือไว้เพียงกราฟเชิงข้อมูลทางคอมพิวเตอร์เท่านั้น