

Thesis target: สร้างคำอธิบายรูปภาพและกราฟใน academic documents โดยใช้ visual content + document context.
คำถามหลักหลังอ่าน paper ชุดนี้: context แบบใดช่วย caption จริง, context ควรถูก retrieve อย่างไรจาก PDF, และจะประเมิน faithfulness/context relevance แยกจาก lexical overlap อย่างไร

Executive Map

Paper	Focus	What it proves	Gap left for thesis
LaMP-Cap (2025)	Dataset + multimodal profile	Profile figures จาก paper เดียวกันช่วยให้ caption ใกล้เคียง author-written caption มากขึ้น	ยังใช้ curated profile ไม่ใช่ context retrieval จาก raw PDF หรือ full document
Author-Specific Context (2025)	Prompt pipeline + refinement	Context filtering และ profile-based few-shot refinement ลด irrelevant content และเพิ่ม style alignment	Pipeline ยังพึ่ง prompt optimizer/reranker คลายตัว และไม่ได้เป็น layout-aware retrieval
Personalized SciFigCap (2025)	Fine-tuned Qwen + quality-aware generation	Paragraph, mention, OCR, profile เพิ่ม performance แต่ style matching ชนกับ quality	ต้องแยก metric สำหรับ style, quality, faithfulness, context relevance

1 Paper 1: LaMP-Cap

Full title: LaMP-Cap: Personalized Figure Caption Generation With Multimodal Figure Profiles
arXiv: 2506.06561 **Authors:** Ho Yin “Sam” Ng, Ting-Yao Hsu, Aashish Anantha Ramakrishnan และคณะ
Repo files: papers/8-LaMPCap_2025.* และ docs/synthesis/8-LaMPCap_2025-analysis.html

1.1 Core Idea

LaMP-Cap เปลี่ยนจาก “generate caption จาก target figure อย่างเดียว” เป็น “generate caption จาก target figure พร้อม profile figures จาก paper เดียวกัน” โดยถือว่า profile figures สะท้อนทั้ง domain context, writing style, terminology และวิธีที่ผู้เขียนอธิบาย visual evidence ใน paper นั้น

แก่นของ paper: ถ้าอยากให้ caption ไม่ generic ต้องให้โมเดลเห็นตัวอย่าง caption/figure อื่นจาก paper เดียวกัน เพราะ scientific captions มักมี style และ vocabulary เฉพาะของ paper/author

1.2 Task Definition แบบละเอียด

Element	Description
Target figure	รูปที่ต้อง generate caption
Target source	target image + figure-mentioning paragraphs เช่นย่อหน้าที่มี “Figure 3 shows...”
Profile figures	รูปอื่นจาก paper เดียวกัน สูงสุด 3 รูป
Profile source	profile image + profile figure-mentioning paragraph
Profile caption	caption จริงของ profile figure ใช้เป็น signal ด้าน style/structure
Output	caption ของ target figure ที่ควรใกล้เคียง author-written caption

1.3 Dataset Construction

- Source dataset คือ SciCap Challenge Dataset จาก arXiv papers
- เลือกหนึ่ง figure ต่อ paper เป็น target และใช้ figures ที่เหลือเป็น profile
- paper ที่มี figure เดียวถูกตัดออก เพราะไม่มี profile ให้ใช้
- จำกัด profile สูงสุด 3 รูป เพราะ SciCap Challenge จำกัดจำนวน figure ต่อ paper
- train/validation/test ตาม split เดิม 80/10/10

Scale: 110,828 target figures; 197,075 profile figures; 307,903 total figures. Figure types หลักคือ Graph Plot, Node Diagram, Equation, Bar Chart, Scatterplot.

1.4 Experimental Setup

Setting	Meaning
No-Profile	ใช้ target image + paragraph เท่านั้น
One-Profile	เพิ่ม profile figure หนึ่งชุดจาก paper เดียวกัน
All-Profile	ใช้ profile figures ทั้งหมดที่มี
Same-paper profile	profile มาจาก paper เดียวกัน ใช้วัด personalization/context effect
Metric	BLEU, ROUGE, BERTScore และบางการทดลองมี human evaluation

1.5 Key Findings

- Profile information ช่วยให้ generated caption ใกล้เคียง ground-truth author captions มากขึ้นในหลาย model
- All-Profile มักดีที่สุด แต่ gain หลักเกิดจาก No-Profile ไป One-Profile แปลว่า context ชั้นแรกที่เกี่ยวข้องสำคัญมาก
- ใน ablation, profile caption สำคัญที่สุด เพราะให้ทั้ง style และ target format; profile image สำคัญกว่า paragraph ในหลายกรณี แปลว่า multimodal profile มีประโยชน์จริง ไม่ใช่แค่ text context
- BERTScore ระหว่าง target และ profile captions สูง แต่ ROUGE-L กระเจายกว้าง แปลว่า profile captions มี semantic relatedness แต่ไม่ได้ copy wording เหมือนกัน
- Qwen-2.5-VL-7B มี failure rate สูงกว่า model อื่นในบาง profile setting เป็น warning ว่า open-source VLM ต้องมี validation/fallback

1.6 Limitations ที่ควรอ้างอิงเป็น Gap

- Context ยังเป็น **profile figures ที่ curated แล้ว** ไม่ใช่ context ที่ retrieve จาก PDF จริง
- ยังไม่ตอบว่า context จาก abstract, methodology, results section, nearby text หรือ cross-reference ช่วยมากกว่า profile figures หรือไม่
- การ optimize ให้ใกล้เคียง author-written caption อาจไม่เท่ากับการได้ caption ที่ factual หรือ useful เพราะ original caption อาจสั้น/คลุมเครือ
- Evaluation ยังพึ่ง lexical/semantic similarity metrics เป็นหลัก

1.7 How to Use in Thesis

- ใช้ LaMP-Cap เป็น baseline dataset สำหรับทดลอง context-aware captioning
- เปลี่ยนจาก fixed profile context เป็น RAG ที่ retrieve context คลายระดับจาก paper
- ทำ ablation เทียบ: target only, mention paragraph, OCR, section context, profile figure, retrieved full-document context
- ใช้ finding “One-Profile gives large gain” เป็นเหตุผลว่า retrieval quality สำคัญกว่า context length

2 Paper 2: Leveraging Author-Specific Context for Scientific Figure Caption Generation

Full title: Leveraging Author-Specific Context for Scientific Figure Caption Generation: 3rd SciCap Challenge
arXiv: [2510.07993](#) **Authors:** Watcharapong Timklaypachara, Monrada Chiewhawan, Nopporn Lekuthai, Titipat Achakulvisut
Repo files: papers/9-AuthorContextSciCap_2025.*

2.1 Core Idea

Paper นี้เป็น system paper สำหรับ SciCap Challenge ที่ใช้ LaMP-Cap แล้วออกแบบ two-stage pipeline: ขั้นแรกสร้าง caption ที่ content-grounded ด้วย context filtering + category-focused prompt optimization ขั้นที่สอง refine caption ด้วย profile figures เพื่อให้ style ใกล้เคียง paper ต้นฉบับ

แก่นของ paper: ถ้าเอา paragraph ส่งเข้า LLM ตรง ๆ จะเกิด noisy caption และ hallucination จึงต้อง filter context ก่อน แล้วค่อย refine style ด้วย profile examples

2.2 Pipeline แบบละเอียด

Module	Input/Process	Purpose
Context filtering	paragraph data จาก target figure	ลบ irrelevant content ก่อน generation
Category-focused prompt	paper category เช่น CS, Math, Physics, Statistics	ให้ prompt ใช้ terminology/structure ที่เหมาะสมกับ domain
MIPROv2	bootstrap instruction-example pairs + Bayesian optimization	optimize prompt โดยเน้น ROUGE-L precision
SIMBA	feedback-driven optimization	หา reasoning path และแก้ problematic cases
Candidate selection	captions จากหลาย category/prompt	เลือก caption ที่ alignment ดีกว่า

Profile refinement	profile figures/captions เป็น few-shot examples	ปรับ style, length, conciseness และ author alignment
--------------------	---	--

2.3 Important Design Choices

- ใช้ category-focused prompts เพราะ scientific papers ต่าง field มี caption convention ต่างกัน
- paper ที่มีหลาย category สร้างหลาย candidate แล้วเลือกภายหลัง แทนการบังคับให้ prompt เดียวครอบคลุมทุก field
- Stage 2 กำหนดความยาวประมาณ $\pm 15\%$ เพื่อแก้ปัญหา caption ที่ verbose จาก Stage 1
- ใช้ profile captions เป็น structural reference ไม่ใช่แค่ข้อมูล factual
- ใช้ Gemini-2.5-flash เป็น reranker เพื่อเน้น precision/style consistency

2.4 Results แบบละเอียด

Experiment	Reported result	Interpretation for thesis
Filtered paragraph + prompt optimization	ROUGE-1 recall 0.4867 $\rightarrow$ 0.5443; ROUGE-2 recall 0.2223 $\rightarrow$ 0.2572	Filtering ช่วย coverage แต่ต้องระวัง precision ลด
Category-focused prompting	ROUGE-1 recall +8.3%; BLEU-4 loss จำกัดกว่า non-category prompt	Domain-aware generation สำคัญสำหรับ academic caption
Non-category-focused prompting	recall เพิ่มขึ้น แต่ precision ลดหนัก	context เยอะ/กว้างเกินไปทำให้ caption verbose และ off-topic
Gemini reranking	ROUGE precision +3.46 ถึง +4.43%	มี post-generation selector ช่วยลด caption ที่ไม่ตรงประเด็น
Profile-informed refinement	BLEU +40–48%; ROUGE precision +25–27%	profile context ช่วย style และ conciseness ชัดเจน

2.5 Limitations ที่ควรอ้างเป็น Gap

- ยังเป็น prompt-engineering-heavy pipeline ต้องใช้ DSPy optimizer, reranker และ few-shot refinement หลายชั้น
- Category-focused prompt ไม่ใช่ retrieval จาก document structure จริง เช่น section, layout, table, figure proximity
- ใช้ BLEU/ROUGE เป็นหลัก ทำให้วัด lexical overlap มากกว่า visual faithfulness
- ไม่ได้เสนอ full PDF ingestion pipeline จึงยังไม่แก้ไข end-to-end academic document understanding

2.6 How to Use in Thesis

- ใช้เป็น argument ว่า **context filtering is necessary**
- เปลี่ยน context filtering จาก prompt/manual rule เป็น retrieval module: mention detector, section-aware retrieval, semantic retrieval, OCR alignment
- เพิ่ม evaluator ที่ตรวจ hallucination หลัง generation แทนพึ่ง reranker จาก metric overlap อย่างเดียว
- ทำ comparison: prompt-optimized context vs RAG-retrieved context

3 Paper 3: Personalized Scientific Figure Caption Generation

Full title: Personalized Scientific Figure Caption Generation: An Empirical Study on Author-Specific Writing Style Transfer

arXiv: [2509.25817](#) **Authors:** Jaeyoung Kim, Jongho Lee, Hongjun Choi, Sion Jang

Repo files: papers/10-PersonalizedSciFigCap_2025.*

3.1 Core Idea

Paper นี้ถามตรง ๆ ว่า author profile data ช่วย personalized figure captioning แคไหน และที่สำคัญกว่านั้นคือการทำให้ caption เหมือน author-written caption อาจไม่เท่ากับการทำให้ caption คุณภาพดีขึ้น ผู้เขียนจึงเพิ่ม quality evaluator และทดลอง quality-aware generation

แก่นของ paper: Context/profile เพิ่ม BLEU/ROUGE ได้ แต่ metric เหล่านี้อาจ reward style imitation มากกว่า informativeness จึงต้องแยก quality objective ออกจาก style objective

3.2 Architecture และ Input

Component	Detail
$f_{quality}$	Qwen-2.5-VL-3B fine-tuned เพื่อให้คะแนน caption quality 1–6

Quality labels	สร้าง synthetic labels ด้วย GPT-4.1 จาก figure-caption pairs
<i>g_{caption}</i>	Qwen-2.5-VL-7B fine-tuned เป็น caption generator
Target inputs	figure image F , explanatory paragraphs P , textual mentions M , OCR text O
Profile inputs	related figures จาก paper เดียวกัน พร้อม F, P, M, O, C
Training filter	ใช้เฉพาะ samples ที่ $f_{quality}$ ทำนาย quality score ≥ 3

3.3 Quality Evaluator Details

- สร้าง synthetic quality assessment dataset 3,000 samples ด้วย GPT-4.1
- fine-tune Qwen-2.5-VL-3B เพื่อประเมิน score 1 = low quality ถึง 6 = high quality
- validation 200 samples ได้ Spearman rank correlation 0.759 และ Quadratic Weighted Kappa 0.754
- เหตุผลที่ต้องมี evaluator: caption จาก arXiv จำนวนมากมีคุณภาพต่ำ การ train ตรง ๆ จาก reference อาจทำให้ model copy low-quality captions

3.4 Caption Generator Details

- ใช้ Qwen-2.5-VL-7B เป็น generator เพราะเป็น open-source VLM ที่ fine-tune ได้
- fine-tune 1 epoch ด้วย AdamW, learning rate $2e-5$, batch size 2
- input รวม target context และ profile context จาก paper เดียวกัน
- ประเมินบน personalized SciCap/LaMP-Cap test set ด้วย BLEU และ ROUGE

3.5 Results แบบละเอียด

Finding	Number	Interpretation
Fine-tuned Qwen ชนะ Gemini บน full test	BLEU-4 0.304 vs 0.278; ROUGE-L 0.555 vs 0.540	open-source VLM fine-tuning เป็น baseline ที่ทำได้จริงสำหรับ thesis
เพิ่ม paragraph จาก F+C baseline	BLEU-4 0.123 $\rightarrow$ 0.295; ROUGE-L 0.355 $\rightarrow$ 0.545	paragraph context เป็น signal ใหญ่มาก ไม่ควรทำ image-only
เพิ่ม mention และ OCR	full config BLEU-4 0.304; ROUGE-L 0.555	mention/OCR เพิ่ม gain แบบ incremental แต่สำคัญสำหรับ factual detail
profile quantity effect	3 profile figures มักได้คะแนนสูงสุด	context มากขึ้นช่วย แต่ต้องดูคุณภาพ context ด้วย
Generated quality issue	Gemini และ Qwen ได้ quality score เฉลี่ยราว 3 และต่ำกว่า author captions	style-matching ไม่พอ ต้องมี quality objective
Forced-Q6	quality score สูงขึ้น แต่ ROUGE-L อาจลด	metric overlap อาจหลงโทษ caption ที่ informative กว่า reference

3.6 Quality-Style Trade-off

ประเด็นที่ควรเอาไปเขียน research gap คือ style fidelity และ caption quality อาจอยู่คนละ objective โมเดลที่ optimize ให้ใกล้เคียง author caption อาจเรียนรู้ wording/style ของผู้เขียน แต่ไม่ได้ guarantee ว่า caption factual, informative หรือ useful กว่าเดิม ในกรณี reference caption คุณภาพต่ำ การ generate caption ที่ดีกว่าอาจทำให้ ROUGE ลด เพราะ wording ไม่ตรง reference

3.7 Limitations ที่ควรอ้างเป็น Gap

- Quality evaluator พึ่ง GPT-4.1 labels จึงยังมี judge bias และควรตรวจด้วย human/domain expert
- Metrics หลักยังเป็น BLEU/ROUGE ทำให้แยกไม่ได้ว่า score สูงเพราะ factual ดีหรือแค่ wording เหมือน
- ใช้ LaMP-Cap fields ที่ curated แล้ว ยังไม่ได้ parse PDF เอง
- ยังไม่ประเมิน visual faithfulness และ context faithfulness อย่างเป็นระบบ

3.8 How to Use in Thesis

- ใช้ Qwen-2.5-VL-7B fine-tuned เป็น open-source baseline
- ใช้ input components F, P, M, O เป็น ablation design สำหรับ thesis
- เพิ่ม evaluation dimensions: visual faithfulness, context relevance, academic informativeness, style similarity
- ใช้ quality-aware idea เป็น refinement/checking module หลัง generation

4 Research Gap ที่เขียนต่อใน Proposal ได้ทันที

Gap	หลักฐานจาก paper	Thesis contribution ที่เสนอได้
-----	------------------	--------------------------------

Context Integration Gap	LaMP-Cap ใช้ profile figures; Author-Specific ใช้ filtered paragraph/profile; Personalized ใช้ curated P, M, O	สร้าง multi-level context retriever จาก PDF จริง: mention paragraph, section, OCR, nearby text, cross-reference
End-to-End Gap	ทั้ง 3 งานเริ่มจาก dataset fields ที่เตรียมไว้แล้ว	ทำ pipeline PDF → layout parsing → figure extraction → context retrieval → caption generation
Evaluation Gap	BLEU/ROUGE เพิ่มแต่ quality อาจไม่เพิ่ม; Forced-Q6 ทำให้ ROUGE ลดได้	เสนอ evaluation framework แยก visual faithfulness, context relevance, informativeness, lexical similarity
Retrieval Quality Gap	One-Profile ให้ gain ใหญ่; non-category prompt เพิ่ม recall แต่ลด precision	ศึกษาว่า context ที่ถูก retrieve แบบไหนดีที่สุด และ context เยอะแค่ไหนจึงเริ่มทำให้ noisy
Open-source Feasibility Gap	Qwen fine-tuned ชนะ Gemini ในบาง setting แต่มี failure risk ในงานอื่น	สร้าง reproducible baseline ด้วย open-source VLM + validation/fallback layer

Working thesis claim: Existing 2025 work shows that context improves scientific figure captioning, but current methods rely on curated profile/context fields and lexical metrics. This thesis will investigate an end-to-end, layout-aware, retrieval-based pipeline that extracts context directly from academic PDFs and evaluates generated captions for visual faithfulness, context relevance, and academic informativeness.

5 Experiment Plan จาก Literature

1. **Baseline:** image-only VLM captioning
2. **Context ablation:** +mention paragraph, +OCR, +section context, +nearby text, +profile figures, +RAG retrieved context
3. **Retrieval comparison:** lexical figure-reference retrieval vs semantic retrieval vs section-aware retrieval
4. **Generation comparison:** prompt-based VLM vs fine-tuned Qwen2.5-VL vs RAG+VLM
5. **Evaluation:** BLEU/ROUGE/BERTScore plus LLM/human rubric for faithfulness, context relevance, informativeness

Generated with local LaTeX skill. Source papers: arXiv:2506.06561, 2510.07993, 2509.25817.